

Introducción al multiprocesamiento

Pedro O. Pérez M., Phd.

Multiprocesadores
Tecnológico de Monterrey

pperezm@tec.mx

08-2022

① Conceptos básicos

Multitarea, multiprogramación y multiprocesamiento

- Multitarea

- Multiprogramación

- Multiprocesamiento

Paralelismo vs. Concurrencia

Paralelismo

- Algoritmos paralelos

- Condición de carrera

- Interbloqueo (Deadlock)

- Coherencia del cache

- Tipos de paralelismo

② Modelo de computación

Single Instruction stream, Single Data stream - SISD

Single Instruction stream, Multiple Data stream - SIMD

Multiple Instruction stream, Single Data stream - MISD

Multiple Instruction stream, Multiple Data stream - MIMD

Cálculo de desempeño

③ Modelos de algoritmos paralelos

Paralelo de datos

Grafo de tareas

Work pool

Maestro-esclavo

Productor-consumidor

La multitarea, o tiempo compartido (time sharing, multitasking), es una extensión lógica en la que el CPU cambia de trabajo con tanta frecuencia que los usuarios pueden interactuar con cada trabajo mientras se está ejecutando.

- El tiempo de espera debe ser menor a un segundo.
- Cada usuario tiene, al menos, un programa ejecutándose en la memoria (proceso).
- Existe muchos trabajos listos para ejecutarse (calendarización del CPU).
- Si los procesos no caben.^{en} memoria, existe un proceso que mueve a otro procesos desde y hacia memoria para que haya espacio en la memoria (swapping). Este es lo que se conoce como memoria virtual (memoria secundaria).

La multiprogramación (multiprogramming) se desarrolla como una solución para el uso eficiente de un servidor:

- Un solo usuario no puede mantener al CPU y a los dispositivos de E/S ocupados todo el tiempo.
- La multiprogramación organiza los trabajos para que el CPU siempre tenga algo que hacer.
- Existe una fila de trabajos (o tareas) en memoria. Desde esta fila, un trabajo es seleccionado a través de un algoritmo de calendarización.
- Cuando un trabajo está esperando a que termine una operación de E/S, el sistema operativo lo desaloja para poder ejecutar otro trabajo.

- Han crecido en uso e importancia.
- También conocidos como sistemas paralelos, sistemas estrechamente acoplados.
- Ventajas: mayor rendimiento, economía a escala, confiabilidad.
- Dos tipos: asimétricos (un procesador controla los demás), simétricos (cada procesador realiza la tarea que haya disponible).

- El cómputo paralelo está fuertemente relacionado con el cómputo concurrente. Es muy frecuente se empleen juntas, incluso que se combinen; sin embargo son muy diferentes: podemos tener paralelismo sin concurrencia (como el paralelismo a nivel de instrucción) y podemos tener concurrencia sin paralelismo (como la multitarea).
- En el cómputo paralelo, una tarea se divide en varias sub-tareas muy similares que se pueden procesar de forma independiente y cuyos resultados se combinan para formar la solución final.
- En la computación concurrente, los diversos procesos no ejecutan tareas relacionadas; cuando lo hacen, las tareas pueden ser de una naturaleza variada y, muy a menudo, requieren alguna comunicación entre procesos durante la ejecución.


Paralelismo es el proceso de ejecutar varias instrucciones simultáneamente. Su objetivo es reducir el tiempo de ejecución total. El paralelismo requiere de hardware con múltiples procesadores. Las computadoras paralelas requieren algoritmos paralelos, lenguajes de programación, compiladores y sistemas operativos que admitan la multitarea.



Fuente: https://upload.wikimedia.org/wikipedia/commons/thumb/d/d3/IBM_Blue_Gene_P_supercomputer.jpg/1280px-IBM_Blue_Gene_P_supercomputer.jpg

- Como recordarás, un algoritmo es una secuencia finita de pasos que toma un conjunto de entradas para producir una tarea. Pues bien, un algoritmo paralelo es un algoritmo que puede ejecutar varias instrucciones simultáneamente en diferentes procesadores y luego combinar todas las salidas individuales para producir el resultado final.
- No es fácil dividir un problema en subproblemas. Nos enfrentamos a problemas tales como condición de carrera, interbloqueos o coherencia de cache.
- También hay que considerar el tiempo que necesitan los procesadores para comunicarse entre sí, ya que éste es mayor que el tiempo real de procesamiento. Por lo tanto, al diseñar un algoritmo paralelo, se debe considerar la utilización adecuada de la CPU para obtener un algoritmo eficiente.

La condición de carrera se da cuando la salida o estado de un proceso es dependiente de una secuencia de eventos que se ejecutan en orden arbitrario y van a trabajar sobre un mismo recurso compartido, se puede producir un error cuando dichos eventos no se ejecutan en el orden que el programador esperaba.



Fuente: https://en.wikipedia.org/wiki/Race_condition

- La memoria cache es un componente usado por el CPU para reducir el costo promedio (en tiempo o energía) de acceso a los datos que se encuentran en memoria principal.
- La mayoría de los CPUs tienen varias memorias cache independiente, de datos o instrucciones, que se encuentran organizados en una jerarquía de varios niveles (L1, L2, etc.).
- La información que se cargan en la memoria cache depende de algoritmos sofisticados y ciertas suposiciones sobre el código del programa. El objetivo del sistema cache es garantizar que el CPU tenga el siguiente bloque de datos que necesitará ya cargado en memoria.

Para mayor rendimiento en un sistema multiprocesador, cada procesador generalmente tiene su propio cache. La coherencia de cache se refiere al problema de mantener la coherencia de los datos de estas caches. El principal problema es lidiar con las escrituras de un procesador.


<https://bit.ly/2TPTmhy>

- Paralelismo a nivel de instrucción.
 - Nivel de bits.
 - Pipelining.
 - Super-escalar.
- Paralelismo a nivel de procesador.
 - Arreglo de computadoras.
 - Multiprocesadores.


- El paralelismo a nivel de bit es una forma de computación paralela basada en el aumento del tamaño de la palabra del procesador. Aumentar el tamaño de palabra reduce el número de instrucciones que el procesador debe ejecutar para realizar una operación en variables cuyos tamaños son mayores que la longitud de la palabra.
- Otra manera es el aumento del ancho del bus de datos externo. Por ejemplo, DDR1 transfiere a 128 bits por ciclo de reloj, mientras que DDR2 transfiere un mínimo de 256 bits por ráfaga.

- Un programa de computadora es, en esencia, una secuencia de instrucciones ejecutadas por un procesador. Si el paralelismo a nivel de instrucción, un procesador solo podría ejecutar menos de una instrucción por ciclo de reloj (Instruction Per Cycle, $IPC < 1$). Este tipo de procesadores se conocen como sub-escalares.
- Sin embargo, las instrucciones pueden reordenarse y combinarse en grupos que luego se ejecutan en paralelo sin cambiar el resultado del programa.

- Todos los procesadores modernos tiene tuberías de varias etapas. Cada etapa en la tubería corresponde a una acción diferente que el procesador realiza en una instrucción en esa etapa; un procesador con una tubería de N etapas puede tener hasta N instrucciones diferentes en diferentes etapas de ejecución (ciclo Fetch-Decode-Execute) y, por lo tanto, puede emitir una instrucción por ciclo de reloj ($IPC = 1$). Estos procesadores se conocen como escalares. Un ejemplo son los procesadores RISC que cuentan con cinco etapas: búsqueda de instrucción (IF), decodificación de instrucción (ID), ejecución (EX), acceso a memoria (MEM) y recuperación de registro (WB).
- **Considera que un Intel Core i7-7700K tiene un IPC, usando un solo hilo, de 174.**



(a)



(b)

Figura: <https://bit.ly/2MuP1PG>

- Sin embargo, la mayoría de los procesadores actuales tiene múltiples unidades de ejecución. Por lo tanto, si combinamos el IPC de un solo hilo con los múltiples hilos ejecución tenemos un mayor IPC. Estos procesadores se conocen como super-escalares.
- De nuevo, tomemos el ejemplo del Intel Core i7-7700K, el cual cuenta con 8 hilos de ejecución. Este procesador super-escalar tiene un IPC de 872.

¿Dónde se están usando este tipo de algoritmos?

Revisa esta página:

<https://builtin.com/hardware/parallel-processing-example>

Tanto las computadoras secuenciales como las paralelas trabajan con un conjunto (o flujo) de instrucciones y un conjunto de datos de entrada. Según el flujo de instrucciones y el flujo de datos, las computadoras se pueden clasificar en cuatro categorías:

- Flujo de instrucciones único, flujo de datos únicos (Single Instruction stream, Single Data stream - SISD).
- Flujo de instrucciones únicos, flujo de datos múltiples (Single Instruction stream, Multiple Data stream - SIMD).
- Flujo de instrucciones múltiples, flujo de datos único (Multiple Instruction stream, Single Data stream - MISD).
- Flujo de instrucciones múltiples, flujo de datos múltiples (Multiple Instruction stream, Multiple Data stream - MIMD).

Single Instruction stream, Single Data stream - SISD


En este tipo de computadoras, el procesador recibe un único flujo de instrucciones y opera con un único flujo de datos procedente de la memoria.



Fuente: https://www.tutorialspoint.com/parallel_algorithm/images/sisd_computers.jpg

Single Instruction stream, Multiple Data stream - SIMD

- Una sola unidad de control envía instrucciones a todas las unidades de procesamiento.
- Cada una de las unidades de procesamiento tienen su propia unidad de memoria para almacenar tanto los datos como las instrucciones.
- Algunos procesadores se encuentran ejecutando su conjunto de instrucciones, mientras otros esperan su siguiente conjunto.




Fuente:

https://www.tutorialspoint.com/parallel_algorithm/images/simd_computers.jpg

Multiple Instruction stream, Single Data stream - MISD

Cada procesador tiene su propia unidad de control y comparten una unidad de memoria común. Todos los procesadores reciben instrucciones individualmente de su propia unidad de control y operan en un solo flujo de datos según las instrucciones que han recibido de sus respectivas unidades de control.




Fuente:

https://www.tutorialspoint.com/parallel_algorithm/images/misd_computers.jpg

Multiple Instruction stream, Multiple Data stream - MIMD

Cada procesador tiene su propia unidad de control, unidad de memoria local y unidad aritmética y lógica. Reciben diferentes conjuntos de instrucciones de sus respectivas unidades de control y operan con diferentes conjuntos de datos.



Fuente:

https://www.tutorialspoint.com/parallel_algorithm/images/mimd_computers.jpg

- Una computadora MIMD que comparte una memoria común se conoce como multiprocesadores, mientras que las que utilizan una red de interconexión se conocen como multicomputadoras.
- Según la distancia física de los procesadores, las multicomputadoras son de dos tipos:
 - Multicomputadora: cuando todos los procesadores están muy cerca unos de otros (por ejemplo, en la misma habitación).
 - Sistema distribuido: cuando todos los procesadores están lejos unos de otros (por ejemplo, en las diferentes ciudades).

La velocidad de un programa es el tiempo que tarda el programa en ejecutarse. Esto podría medirse en cualquier incremento de tiempo. SpeedUp se define con el tiempo que le toma a un programa ejecutarse secuencialmente (con un procesador) dividido por el tiempo que lleva ejecutarse en paralelo (con muchos procesadores o hilos).

La fórmula para calcular el SpeedUp es:

Donde:


- S_p – La mejora obtenida al usar p procesadores.
- T_1 - El tiempo que tarda el programa en ejecutarse secuencialmente.
- T_p - El tiempo que tarda el programa en ejecutarse usando p procesadores

$$S_p = \frac{T_1}{T_p}$$

El modelo de un algoritmo paralelo se desarrolla considerando una estrategia para dividir los datos y el método de procesamiento y aplicando una estrategia adecuada para reducir las interacciones. Entre los modelos existentes, encontraremos:

- Paralelo de datos.
- Grafo de tareas.
- Work pool.
- Maestro-esclavo.
- Producto-consumidor.
- Híbrido


- Las tareas se asignan a los procesos y cada tarea realiza tipos similares de operaciones en diferentes datos.
- Se puede aplicar en espacios de direcciones compartidas y paradigmas de paso de mensajes.
- La interacción se pueden reducir seleccionando una localidad que preserve la descomposición, utilizando rutinas de interacción colectiva optimizadas o superponiendo el cálculo y la interacción.
- Ejemplos: Multiplicación de matrices densas.



Fuente:

https://www.tutorialspoint.com/parallel_algorithm/images/data_parallel_model.jpg

- Las tareas se asignan dinámicamente a los procesos para equilibrar la carga.
- Este modelo se utiliza cuando la cantidad de datos es menor que el cálculo asociado con las tareas.
- La tarea puede estar disponible al principio o puede generarse dinámicamente.
- Ejemplos: árboles de búsqueda paralelos.




Fuente:

https://www.tutorialspoint.com/parallel_algorithm/images/work_pool_model.jpg

En el modelo maestro-esclavo, uno o más procesos maestros generan tareas y las asignan a procesos esclavos. Las tareas pueden asignarse de antemano si:

- El maestro puede estimar el volumen de las tareas
- Una asignación aleatoria puede hacer un trabajo satisfactorio de equilibrio de carga
- A los esclavos se les asignan tareas más pequeñas en diferentes momentos.

También se conoce como modelo "pipeline". Un conjunto de datos se transmite a través de una serie de procesos, cada uno de los cuales realiza alguna tarea en él. La llegada de nuevos datos genera la ejecución de una nueva tarea por un proceso en la cola. Los procesos podrían formar una cola en forma de matrices lineales o multidimensionales, árboles o grafos generales con o sin ciclos.



Fuente:
https://www.tutorialspoint.com/parallel_algorithm/images/pipeline_model.jpg